

다변량 시계열 이상징후 탐지

선택목

1. 문제 정의 및 데이터 이해(분석)

1.1 문제 정의

본 과제는 정상 데이터만으로 학습된 기계학습 모델이 이후 입력되는 데이터에서 이상치를 탐지하는 준지도 학습 기반 이상치 탐지 문제이다. 학습 데이터에는 라벨이 존재하지 않으며, 모델은 정상 패턴을 학습한 뒤 정상 분포에서 벗어난 샘플을 이상치로 판별한다.

1.2 EDA (Exploratory Data Analysis)

데이터는 다변량 시계열 데이터이며, 각 타임스텝은 10 개의 채널로 구성된다. Validation set 의 경우 이상치 비율은 약 15.6%로 클래스 불균형이 존재한다. 즉, AUROC 는 음성(정상) 클래스가 다수인 경우 과하게 높게 측정이 될 수 있으므로, AUPR 을 함께 평가 지표로 사용한다. 10 개의 채널은 이산형(0 과 1), 연속형 두 유형으로 구분된다.


- 이산형(3 개): x_06, x_92, x_4b
- 연속형(7 개): x_b1, x_29, x_7e, x_5c, x_f8, x_d4, x_3a

이산형 feature 는 거리 기반 모델(L0F)이나 밀도 기반 모델(GMM)에 raw 값을 그대로 학습할 경우 연속형과의 스케일 불균형 및 거리 계산 왜곡이 발생할 수 있다. 반면 트리 기반 모델(IF)에서는 이산형을 별도의 방식으로 변환하여 활용할 수 있다. 즉, 이러한 feature 유형은 모델별로 데이터를 분리하여 설계하는 근거가 된다.

연속형 채널에 대한 자기상관함수(ACF) 분석 결과, x_f8 을 제외한 6 개 채널에서 약 500 lag 주기로 ACF 최댓값이 반복되는 강한 주기성이 확인되었다. 이는 현 시점의 데이터가 약 500 timestep 전의 과거 패턴과 밀접하게 연계되어 있음을 의미한다. 따라서 과거 구간의 통계량이 현재 시점의 정상 여부를 판단하는 맥락 정보로 활용될 수 있으며, 이는 rolling window 의 근거가 된다.

특히 x_f8 채널에서는 주기성과 함께 trend 가 동시에 관찰되었다. Train 구간에서는 증가 추세, Validation 구간에서는 감소 추세를 보였고, 이는 데이터가 구간에 따라서 서로 다른 분포를 보이기에 모델이 예측하기에 까다로운 상태임을 나타낸다. 즉, 모델이 train 의 x_f8 값 범위를 정상으로 학습하더라도, val/test 에서 추세가 반전되어 실제 정상 데이터가 모델 관점에서 이상치로 판단할 수 있음을 의미한다.

채널 간 상관관계를 분석한 결과, x_06 과 x_3a 간 상관계수가 약 1.0 에 근접하였으며 x_d4, x_4b, x_5c 사이에서도 0.96 이상의 높은 상관관계가 확인되었다. 이는 일부 feature 가 중복된 정보를 담고 있음을 의미한다. 중복 feature 를 그대로 모델에 학습시키면 해당 feature 에 대해서만 너무 과하게 학습하여 데이터의 전체적인 특징을 왜곡해서 해석할 수 있고 거리와 밀도 추정의 품질을 저하시킬 수 있다. 이러한 관찰은 LOF 혹은 GMM 실험에서 PCA 를 통해 중복 정보를 제거하는 근거가 된다.



연속형 7 개 채널 데이터를 표준화와 PCA 를 적용한 뒤 주성분 공간(PC1-PC2)에서 데이터 분포를 시각화한 결과, 3 개의 독립적인 가우시안 군집을 형성했다.

또한 Validation set 의 이상치는 Train 군집의 경계 바깥이나, 덩어리 사이사이에 텅 빈 공간에 떨어져 있는 것을 확인하였다. 이는 이번 과제에서 GMM 을 선택한 근거가 된다.

2. 전처리

2.1 결측치 처리

모든 데이터셋의 결측치는 선형 보간을 적용하였다. 다만, 데이터의 맨 첫부분이나 맨 끝부분은 앞뒤에 참고할 데이터가 없어 여전히 빈칸으로 남게 된다. 이럴 경우에는 맨 첫부분에 대해서는 뒤칸에 나오는 첫 번째 정상 데이터를 앞으로 당겨 채웠고, 맨 뒤의 빈칸은 앞에 있는 마지막 정상 데이터를 그대로 뒤로 밀어서 채웠다.

2.2 x_f8 distribution shift 처리

EDA 에서 x_f8 은 데이터 분포 변화가 가장 심한 채널로 확인되었다. 이를 해결하기 위해 x_f8 에 1 차 차분을 적용하여 trend 를 제거하고 변화량 기반 표현으로 전환하였다.

2.3 Rolling Window 기반 feature 추출

단일 타임스텝의 raw 데이터만으로는 현재 값이 과거의 정상적인 패턴에서 얼마나 이탈했는지 포착하기 어렵다. EDA 에서 확인된 주기성은 일정 구간의 통계량이 정상적인 맥락을 파악하는 데 유효함을 시사하므로, rolling window

기반 feature 추출을 도입했다.



작동 방식은 다음과 같다. 각 타임스텝 t에서 이전 최대 W개의 값을 참조하여 통계량을 계산한다. 이때 sliding window처럼 고정된 구간을 잘라내는 방식이

아니라, 시계열의 처음부터 현재 타임스텝까지 누적된 데이터를 대상으로 통계량을 계산한다. 즉, 초반 타임스텝처럼 참조 가능한 과거 데이터가 W보다 적은 경우에도 min_periods=1로 설정하여 단 하나의 값만 존재하더라도 통계량을 계산하고 결측 없이 타임스텝을 채운다. 이를 통해 rolling 통계 feature의 행 수가 원본 시계열과 동일하게 유지되어 타임스텝 단위의 이상치 점수 산출이 가능하다.

2.4 이산형 채널 처리

이산형 채널의 처리 방식은 모델의 특성에 따라 다르게 결정하였다.

Isolation Forest는 트리 분기 기반 모델로, 이산형 raw 정수값을 그대로 입력하면 데이터가 절대 크기에 과도하게 고정되어 정상 패턴의 다양성을 충분히 반영하지 못한다. 따라서 이산형 채널에 일정 구간을 지정해 평균을 내면, 그 구간 동안 1이 얼마나 있는지에 대한 비율을 알 수 있고, 이 값으로 구간의 전체적인 데이터 모양을 파악할 수 있다.

LOF와 GMM은 각각 거리 계산과 확률 밀도 추정에 기반한다. 이산형 채널은 연속형 채널의 값 범위와 스케일이 다르므로 거리 계산을 왜곡할 수 있으며, 가우시안 분포와도 부합하지 않는다. 따라서 두 모델의 입력으로는 이산형 채널을 제외한 연속형 7채널만 사용하였다.

2.5 스케일 정규화

LOF와 GMM은 채널간 스케일 차이가 모델 동작에 직접 영향을 미친다. LOF는 각 샘플의 밀도를 이웃 간 거리로 추정하는데, 스케일이 큰 채널이 거리 계산을 지배하면 다른 채널의 이상 신호가 묻힌다. GMM은 채널 간 스케일 불균형이 특정 축의 분산을 과도하게 반영하는 문제를 일으킨다. 이를 해결하기 위해 두 모델 모두 train 데이터 기준으로 StandardScaler를 적용하여 각 채널을 평균 0, 분산 1로 정규화하였다.

2.6 차원 축소

EDA에서 확인된 채널 간 높은 상관관계를 고려하여, StandardScaler 이후 PCA를 적용하여 누적 분산 95% 기준으로 차원을 축소하였다. 그 결과 7개 연속형 채널이 4개의 주성분으로 압축되었다.

3. 모델 설계 및 구현

각 모델은 baseline 구성에서 출발하여 EDA에서 확인된 문제를 단계적으로 해결할 수 있도록 설계하였다.

3.1 Isolation Forest

IF는 rolling 통계와 x_f8 차분을 순차적으로 추가하여 시계열 맥락 반영 및 distribution shift 완화를 검증하였다.

- 1 단계: 원본 10채널을 그대로 사용한 baseline 모델.
- 2 단계: 연속형 채널에 rolling 통계(mean, std, min, max, range), 이산형 채널에 rolling mean을 적용하여 시계열 맥락을 반영.
- 3 단계: 2 단계에 x_f8 채널의 1차 차분을 추가하여 distribution shift를 완화.

3.2 Local Outlier Factor

LOF는 StandardScaler를 기반으로 rolling 통계, x_f8 차분, PCA를 단계적으로 적용하여 거리 기반 이상치 탐지 성능을 평가하였다.

- 1 단계: 원본 연속형 7채널에 StandardScaler를 적용한 baseline 모델.
- 2 단계: rolling 통계(mean, std, min, max, range)를 사용하여 시계열 정보를 반영.
- 3 단계: 원본 연속형 7채널을 사용하고 x_f8 차분을 적용하여 distribution shift를 완화.
- 4 단계: 3 단계에서 PCA를 추가하여 상관관계가 높은 변수의 중복 정보를 제거.

3.3 Gaussian Mixture Model

GMM은 StandardScaler와 PCA를 적용한 후 rolling 통계, 분포 통계량(skewness, kurtosis), x_f8 차분을 추가하여 밀도 추정 기반 이상치 탐지 성능을 비교하였다.

- 1 단계: StandardScaler와 PCA를 적용한 후 rolling 통계(mean, std, min, max, range)를 추가.
- 2 단계: skewness와 kurtosis를 추가하여 원도우 내 분포 형태 정보를 반영.
- 3 단계: 1 단계 구성에 x_f8 차분을 추가하여

distribution shift 를 완화.

4. 모델 성능 및 비교 실험/분석

모델 성능은 AUROC 및 AUPR 을 기준으로 평가하였으며, Window size 와 모델 하이퍼파라미터는 validation 성능을 기준으로 최적화하였다. 최종 성능은 public test set 결과를 사용하여 비교하였다. 또한 이상치 유형별 탐지 성능을 분석하기 위해 Point, Contextual, Collective anomaly 에 대한 AUPR 을 별도로 측정하였다.

4.1 Isolation Forest 실험/분석

Window size 는 5, n_estimators 는 100 로 설정하여 실험을 진행했다.

Model	AUROC	AUPR	Point AUPR	Contextual AUPR	Collective AUPR
IF-001	0.6420	0.2198	0.0156	0.0477	0.1925
IF-002	0.7084	0.2511	0.0040	0.0516	0.2218
IF-003	0.7285	0.2705	0.0053	0.0485	0.2439

1 단계에서 2 단계로 전환하면서 AUROC 와 AUPR 이 모두 향상되었으며 특히 Collective AUPR 이 증가하였다. 이는 rolling 통계가 단일 시점보다 구간 단위의 변화 패턴을 반영하여 Collective anomaly 탐지에 도움이 되었기 때문이다. 반면 Point AUPR 은 감소하였는데, rolling 통계 과정에서 순간적인 이상 신호가 평균화가 되어 약해진 것으로 해석된다. 3 단계에서는 x_f8 차분을 추가하여 AUROC 와 AUPR 이 다시 향상되었으며, Collective AUPR 도 증가하였다. 이는 x_f8 의 distribution shift 가 완화되면서 정상 패턴과 이상 패턴을 더욱 안정적으로 구분할 수 있었기 때문이라고 판단된다. 다만 Point AUPR 은 모든 단계에서 매우 낮게 유지되었고, 이는 IF 가 단일 시점의 이상보다 여러 feature 에 걸쳐 나타나는 구간 단위 이상을 더 효과적으로 탐지하는 모델임을 보여준다.

4.2 LOF 실험/분석

LOF-002 의 window size 는 3 으로 설정하였고, n_neighbors 은 10 으로 설정했다.

Model	AUROC	AUPR	Point AUPR	Contextual AUPR	Collective AUPR
LOF-001	0.8058	0.5733	1.0000	0.6608	0.5047
LOF-002	0.7886	0.6395	0.3954	0.6763	0.5841

LOF-003	0.8492	0.7245	1.0000	0.9881	0.6742
LOF-004	0.8128	0.6619	1.0000	0.9739	0.6003

1 단계는 Point AUPR 이 1.0 을 기록했다. LOF 는 거리 기반 모델이므로 단일 시점에서 일부 채널만 크게 벗어나도 정상 군집과 거리가 증가하여 Point Anomaly 를 효과적으로 탐지할 수 있다. 2 단계에서 rolling 통계(W=3)을 추가하고 Point AUPR 이 크게 감소하였고, 이는 rolling 통계가 순간적인 이상 신호를 평균화하여 LOF 의 거리 기반 탐지 능력을 약화시켰기 때문으로 해석된다. 3 단계에서는 rolling 통계 대신 x_f8 차분을 적용하였고, AUPR 이 0.7256 까지 증가하였다. 특히 Contextual AUPR 도 0.9881 로 크게 향상되었다. 이는 원본 거리 정보를 유지하되, x_f8 의 distribution shift 만 완화하여 나온 결과로 볼 수 있다. 4 단계에서 PCA 를 추가하자 모든 지표가 감소하였다. PCA 과정에서 원본 채널의 거리 정보가 일부 손실되면서 LOF 의 성능이 저하된 것으로 판단된다.

4.3 GMM 실험/분석

Window size 20, n_components 는 5 로 설정했다.

Model	AUROC	AUPR	Point AUPR	Contextual AUPR	Collective AUPR
GMM-001	0.9339	0.7110	0.0207	0.5344	0.6566
GMM-002	0.8614	0.6712	0.0718	0.5055	0.6314
GMM-003	0.9283	0.7314	0.2320	0.5214	0.6864

1 단계부터 AUPR 0.7100 을 보이며 강력한 baseline 성능을 보였다. 2 단계에서 skewness 와 kurtosis 를 추가하자 AUROC 와 AUPR 을 포함한 대부분의 지표가 감소하였다. 이는 skewness 와 kurtosis 가 GMM 의 확률 밀도 추정 과정에서 유용한 정보가 되기보다 오히려 불필요한 노이즈와 변동성을 유발하였음을 알 수 있다. 3 단계에서는 1 단계 구성에 x_f8 차분을 추가하였고, 가장 높은 성능을 기록했다. 이는 x_f8 의 distribution shift 가 완화되면서 정상 데이터의 밀도 추정이 더 안정적으로 되었기 때문이라고 판단된다.

4.4 앙상블

앙상블을 진행하기 전에 IF 는 단독 성능이 LOF 와 GMM 에 비해 너무 낮아, rank normalization 후 평균을 수행할 경우 오히려 최종 점수를 희석시킬 가능성이 있다고 판단하여 앙상블 후보에서 제외하였다. 다만 IF 는 실험한 모델 중

유일하게 이산형 채널을 활용한 모델이었다. 이에 따라 LOF-003 에 이산형 3 채널의 rolling mean(W=10)을 추가한 LOF-Disc 모델을 구성하여 실험을 진행하였다.


Model	AUROC	AUPR	Point AUPR	Contextual AUPR	Collective AUPR
LOF-003	0.8492	0.7245	1.0000	0.9881	0.6742
LOF-Disc	0.8471	0.7115	1.0000	0.9544	0.6589

실험 결과, LOF-Disc 는 LOF-003 대비 전반적인 성능이 소폭 감소했다. 이산형 feature 는 거리 기반 모델의 거리 계산을 왜곡할 가능성이 있으며, rolling mean 을 통해 이를 완화하였음에도 왜곡이 발생했다고 판단된다.

LOF-003 과 LOF-Disc 의 이상치 점수는 GMM-003 과 각각 0.27, 0.285 의 낮은 상관계수를 보였다. 이는 두 모델이 서로 다른 특징과 패턴에 반응하고 있음을 의미하고, 점수 결합을 통해 상호 보완 효과를 기대할 수 있다. 두 모델을 각각 GMM-003 과 rank norm 을 한뒤 정규화된 점수를 동일 가중치(0.5:0.5)로 평균화하는 방식으로 앙상블한 결과는 다음과 같다.

Model	AUROC	AUPR	Point AUPR	Contextual AUPR	Collective AUPR
L_003+G	0.9274	0.8149	0.9667	0.9707	0.7795
L_Disc+G	0.9264	0.8084	0.9667	0.9633	0.7716

LOF-Disc 기반 앙상블은 LOF-003 기반 앙상블 대비 Test AUPR 이 0.0065 감소하였고, 다른 평가 지표 또한 낮게 나타났다. 다만 이산형 채널 정보를 추가적으로 반영할 수 있다는 점을 고려해보면, 이 정도의 성능 감소는 모델 확장에 따른 합리적인 trade-off 라고 판단된다. 따라서 성능과 feature 활용 측면을 종합적으로 고려하여 최종 모델로 LOF-Disc 를 선정하였다.



위 두 그래프는 LOF-Disc 와 GMM-003 을 앙상블한 모델의 성능을 확인하기 위한 그래프이다. 왼쪽 그림을 통해 정상

데이터가 주로 낮은 점수 영역에, 이상 데이터가 높은 점수 영역에 분포하는 것을 확인할 수 있다. 오른쪽 그림은 PR Curve 그래프를 시각화한 것이다. LOF-Disc 와 GMM-003 을 앙상블한 모델이 단일 모델들에 비해 가장 안정적으로 하강 곡선을 형성한 것을 볼 수 있다.

4.5 왜 더 작은 Window size 일 경우 성능이 좋은가?

세 모델 모두에서 큰 window($W \geq 200$)보다 작은 window($W \leq 50$)가 더 높은 성능을 보였다. 가장 큰 이유는 rolling 통계가 window 내의 값을 평균적으로 반영하기 때문이다. Window 가 너무 크면 짧게 발생한 이상 구간이 많은 정상 데이터와 함께 계산되어 이상 신호가 약해진다. 반면 작은 window 는 최근 구간의 변화를 더 민감하게 반영할 수 있어 이상 패턴이 통계량에 더 잘 들어난다. 또한 window 가 커질수록 시계열 초반부에서 적은 데이터로 계산되는 rolling 통계 구간이 길어져 feature 분포가 다소 불안정해질 수 있다. 이러한 이유가 rolling window 를 사용할 시에 발생할 수 있는 한계라고 생각한다.

5. 결론 및 한계

본 과제에서는 IF, LOF, GMM 을 단계적으로 개선하며 성능을 비교했다. 실험 결과, 중간 보고의 가설과는 달리 LOF 는 Point anomaly 탐지에 강점을 보였다. 또한 x_{f8} 채널에 대한 차분은 모든 모델에서 distribution shift 를 효과적으로 완화하였으며, rolling window 는 작은 크기에서 더 우수한 성능을 보였다. 한계로는 IF 의 이상치 탐지 성능이 매우 낮았으며, rolling window 방식의 feature 추출 방식에 개선의 여지가 있음을 확인했다.

* point, contextual, collective AUPR 계산 방법

전체 이상 구간을 연속된 길이에 따라 세 유형으로 분류하였다. 길이 1~5 step 은 Point, 6~200 step 은 Contextual, 201 step 이상은 Collective 로 정의하였다. 각 유형별 AUPR 을 계산할 때는 해당 유형의 이상 구간과 전체 정상 구간만을 대상으로 AUPR 을 산출하였다(다른 유형의 이상 구간은 평가에서 제외). 즉 "이 유형의 이상치를 정상과 얼마나 잘 구분하는가"를 유형별로 독립적으로 측정한 것이다.

* <https://github.com/sunuk00/ML-assignment.git>